

# GAN 기반 의료 데이터 증강을 통한 분류 성능 향상

## Improving Classification Results on Medical Dataset Augmentation Using GAN

박길한<sup>01</sup> 이재환<sup>1</sup> 이익규<sup>1</sup> 김지수<sup>2</sup> 허재필<sup>2</sup>성균관대학교 컴퓨터교육과<sup>1</sup>성균관대학교 소프트웨어학과<sup>2</sup>

{ a01152a, jwlee508, dlrrb0521, jisu7935, jaepilheo }@skku.edu

### Abstract

의료 분야의 특성상 데이터 개방성이 낮고 절대적인 데이터의 수가 부족하다. 또한 의료 데이터는 특유의 민감성 때문에 반드시 연구에 필요한 최소 수준의 데이터 요청 및 폐쇄된 환경에서만 활용이 가능해 데이터 접근이 매우 제한적이다. 한정된 의료 데이터의 특성을 해결하기 위한 연구가 다양하게 진행되고 있다. 본 논문에서는 피부암 데이터를 분류하기 위한 모델의 학습에 필요한 의료 데이터의 수를 늘리기 위한 방법으로 GAN을 통한 Data Augmentation을 위해서 소량의 데이터를 학습하고 이를 통해 데이터의 수를 증강한다. 또한 GAN의 모델 별로 실제 이미지와 가짜 이미지의 비율이 어느정도 수준에서 기준이 되는 분류 모델의 정확도에 가까워지는지 실험해본다


## I. Introduction

- 의료 데이터 특성 상 양질의 데이터셋을 확보하는 데에 어려움이 있으며 데이터의 정제와 가공 또한 많은 비용과 전문 인력 투입을 필요로 한다. 특히, 질환이 있는 환자는 정상인에 비해 매우 소수이기에 데이터 클래스 불균형(Class Imbalance)을 야기하여 이는 분류 성능에 매우 악영향을 끼친다.
- 본 연구는 절대적으로 부족한 의료 데이터에 여러 GAN(Generative Adversarial Network)[1] 모델을 적용하여 데이터 증강(Data Augmentation)을 진행한다. 이를 통해 의료 데이터셋 특유의 문제인 클래스 불균형을 해결하여 결론적으로는 분류(Classification) 성능을 향상시키고자 한다.

## II. Proposed Methods

- 실험에 사용할 서로 다른 특성을 가진 3가지 GAN 모델로 DCGAN[5], PGGAN[2], CycleGAN[3]을 선정하였다. DCGAN은 GAN의 기본적인 구조에 CNN을 추가한 초기의 생성 모델이다. PGGAN은 안정적인 고해상도 이미지 생성을 위해 점진적인 Layer를 추가한 모델이다. CycleGAN은 주요 특징은 유지한 상태로 원하는 속성을 가지도록 스타일을 변화시키는 Image to Image Translation[4]의 대표적인 변형 모델이다.
- 본 연구에서는 3가지 GAN을 절대적으로 부족한 악성 종양 이미지 증강에 활용하려 한다.

## III. Experiments



(a) 양성(Benign) 종양

(b) 악성(Malignant) 종양

Figure 1: Kaggle Skin Cancer 이미지 데이터셋 샘플. Kaggle에 공개되어 있는 피부암(Skin Cancer) 이미지 데이터셋으로 (a) 양성(Benign)과 (b) 악성(Malignant) 종양 2가지 클래스의 이진 분류(Binary Classification)를 목적으로 제공되었다. 학습(Train)에 사용할 양성과 악성 종양의 이미지 개수는 각각 1440개, 1197개이며, 테스트(Test)에 사용될 이미지 개수는 각각 360, 300개이다. 모든 이미지의 크기는 224 x 224 이다.

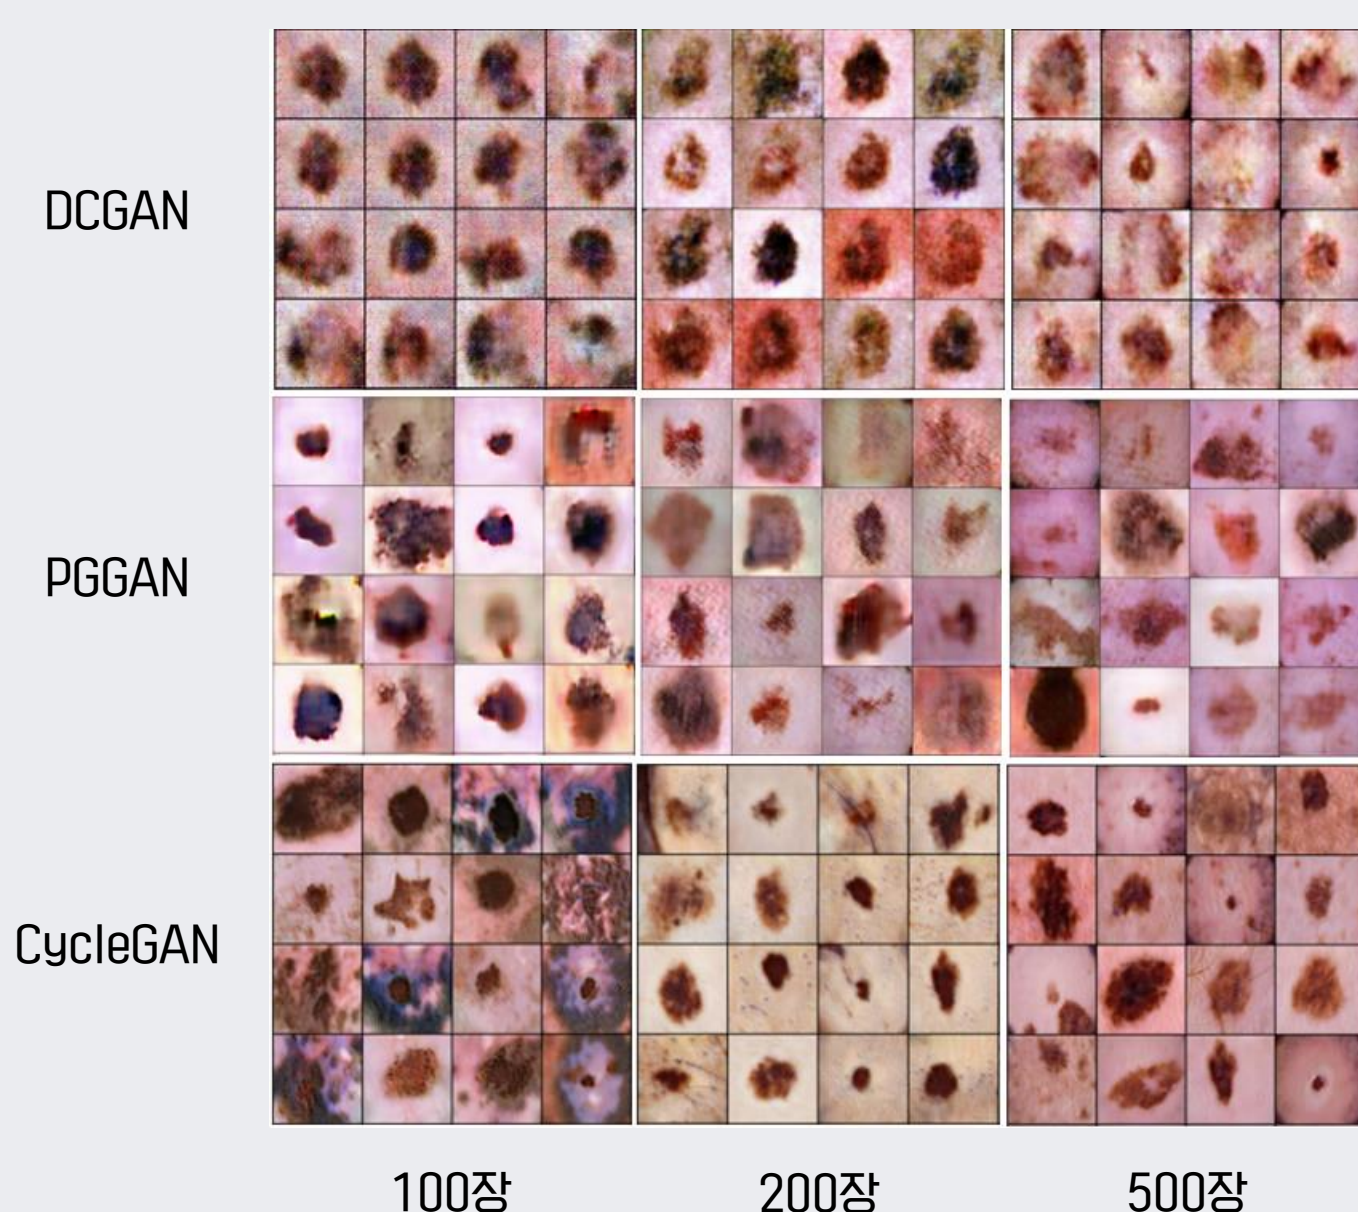


Figure 2: 제한된 악성 종양 데이터 개수로 학습된 GAN 모델로 생성된 Fake 이미지 샘플. 위에서부터 DCGAN, PGGAN, CycleGAN의 모델을 사용하였으며, 모델 학습에 악성 종양 이미지 100장, 200장, 500장을 사용하였다.

Table 1: 데이터 불균형 상태에서의 분류 모델 성능. 양성 종양 이미지 수 전체와 제한된 수 악성 종양 이미지 수(50, 100, 200, 500)를 사용하여 학습된 분류 모델을 성능을 나타낸다. Baseline으로 사용할 분류 모델은 PyTorch 기반의 간단한 CNN 네트워크로 구성하였다. 표 내의 값은 평가지표 'Accuracy' / 'AUROC' 값이다.

모델	악성 종양 이미지 개수 (양성 종양 1440장)			
	50 Images	100 Images	200 Images	500 Images
Baseline	0.58/0.54	0.58/0.54	0.62/0.59	0.81/0.81

Table 2: GAN을 통해 데이터 불균형을 해결한 상태에서의 분류 모델 성능. 3가지의 GAN 모델로 Fake 이미지를 생성하여 악성 종양 이미지 개수를 1197개로 늘린 뒤 학습한 분류 모델의 성능이다. 표 내의 값은 평가지표 'Accuracy' / 'AUROC' 값이다.

모델	악성 종양 이미지 개수 (양성 종양 1440장)			
	50 Images	100 Images	200 Images	500 Images
DCGAN	0.67/0.64	0.57/0.53	0.67/0.64	0.82/0.81
PGGAN	0.58/0.54	0.61/0.57	0.73/0.71	0.81/0.80
CycleGAN	0.57/0.53	0.62/0.58	0.68/0.65	0.82/0.82

- GAN의 초창기 모델로 성능이 뒤처지는 DCGAN의 경우 소량의 이미지 수로는 데이터의 특징을 잘 찾지 못하며 다소 흐릿한 이미지가 생성된다.
- PGGAN은 충분한 이미지 데이터를 가지고 있을 때 고품질의 이미지를 생성하지만, 소량의 데이터로 증강하는 데에는 역시 한계가 존재한다.
- CycleGAN은 이미지의 일부 속성을 변화해 나감으로써 새로운 데이터를 생성하기에 일부 소량의 데이터 수만으로 종양 부위가 겹거나 다양한 분화 상태를 띄는 악성 종양의 구별되는 특징을 잘 찾아낸다.

## IV. Conclusion

- 학습 데이터가 불균형한 상태보다 GAN을 통해 데이터 증강을 한 경우 대부분 눈에 띄게 성능이 올라갔지만, 전체 Real 학습 데이터셋을 사용한 기준 모델에는 미치지 못하였다.
- GAN 학습에 이용되는 Real 이미지 데이터 수가 최소 500장은 되어야 전체 이미지 수를 사용하여 학습한 모델에 버금가는 성능이 나온다.
- 성능 향상을 위해 추후 다른 이미지 증강 기법을 적용하였을 때의 결과와 비교해보고, 다른 최신 GAN을 통한 추가 실험을 진행하여 성능의 변화를 보고자 한다.
- 또한, 단순 이진 분류의 데이터가 아닌 다중 분류의 데이터에서 성능 비교도 진행해보려 한다.

## References

- [1] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In Advances in Neural Information Processing Systems (NIPS), pages 2672–2680, 2014
- [2] Karras, Tero, et al. Progressive Growing of GANs for Improved Quality, Stability, and Variation. arXiv preprint arXiv:1710.10196, 2017.
- [3] J.-Y. Zhu, T. Park, P. Isola, and A. A. Efros. Unpaired imageto-image translation using cycle-consistent adversarial networks. In Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017
- [4] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros. Image-to-image translation with conditional adversarial networks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017.
- [5] A. Radford, L. Metz, and S. Chintala. Unsupervised representation learning with deep convolutional generative adversarial networks. arXiv preprint arXiv:1511.06434, 2015.